

2

size X → 20x354

plot(x(10,:), x(20,:))

?

))

1.1

Se uma matriz de autocorrelação  $n \times n$  tem  $n$  eixos diferentes, então, sendo simétrica positiva e invertível, pode ser decomposta da seguinte forma:

$$R_x = P \Lambda P^T, \text{ onde } P \text{ é uma matriz ortogonal e } \Lambda \text{ é uma matriz diagonal}$$

$$\Lambda = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix}$$

$P$  é a única forma que  $P \Lambda P^T$  seja  $R_x$

$R_x P = P \Lambda \Rightarrow R_x e_i = \lambda_i e_i \Rightarrow$  as colunas de  $P$  são os eixos de  $R_x$

uma  
idp

chamamos, sendo possível maximizar a variância dos coeficientes usando os  $n$  eixos de  $R_x$  como base, concluímos que existe uma base ortogonal em  $R^n$  formada por estes eixos.

Prova por indução:

$$\begin{aligned} \text{Sabemos que } \sigma_{1K}^2 &= \langle P_{1K}^2 \rangle = \langle (W^T X)(X^T W) \rangle = W^T \langle X X^T \rangle W = W^T R_x W = W^T P \Lambda P^T W \\ &= \sum_{i=1}^K W_i^T P R_x P^T W_i = \sum_{i=1}^K W_i^T P \lambda_i P^T W_i = \sum_{i=1}^K W_i^T \lambda_i W_i \end{aligned}$$

$$W^T = [W_1, \dots, W_K] = P^T P$$

$\|W\|^2 = 1$ , pelo fato de  $\lambda_i$  ter coeficiente unitário e  $P$  é uma matriz ortogonal

Assumindo que os primeiros  $K-1$  eixos base são os eixos de  $R_x$ ,  $\sigma_{1K}^2 = \frac{1}{K} \sum_{i=1}^K \lambda_i$

Como os  $\lambda_i$  são ordenados por ordem decrescente, a variância é maximizada por  $W_K = e_K$

$$W = e_K P$$

$$K=1 \Rightarrow W_1 = e_1$$

2.1  
• Ao representar a data, observam-se nuvens de pontos.

• Se a análise das nuvens, verifica-se que há coordenadas que estão relacionadas positivamente, ~~negativamente~~ e outras sobre os quais não é possível obter informação devido à existência de ruído.

• Utilizemos os comandos `plot(x(i,:), x(j,:), 'b.')`, para  $i \neq j$  Para  $i = j$  verificamos os casos explicados anteriormente. Para  $i = j$ , as coordenadas relacionam-se positivamente

2.2

1º → calculate mean:

```
mean = 0
for i = 1:354
    mean = mean + x(0, i)
end
mean = mean / 354
```

calc\_mean(x)

2º → remove the mean:

```
for i = 1:354
    x(:, i) = x(:, i) - mean;
end
```

3º → cálculo de R

$$R = \frac{1}{354} X X^T$$

4º → Calcular os eigenvalues de R: `eig(R)`

5º → ordenar: `sort(eigenvalues, 'descend');`

(6) comparar para obter as direções

2.3

$$\frac{g[L]}{g[P]} \geq 0,95, \quad g[L] = \sum_{k=1}^L D[k, k] \rightarrow \text{eig}(R)$$

11 components

`gP = sum(eigenvalues);`

for  $i = 1:20$

if  $(\text{sum}(\text{orderdig}(1:i)) / gP) \geq 0,95$

break;

end

end

→ verificar se  $i = 11$

2.4

$$\text{Energy} = g_p = \text{sum}(\text{eigvalues})$$

$$g_l = \text{sum}(\text{order}(\text{eig}(1:2)))$$

$$\text{energy} = g_l / g_p = 9.8879$$

Calculate  $V_i$ :

$$R V_i = \lambda_i V_i \rightarrow V_i^T$$

↓  
vectors → columns → 1 eigenvector

2.5

$$Y_{11} = X(10,:) \cdot V(:,20); \quad Y_{12} = X(20,:) \cdot V(:,19)$$

$$Y_{21} = X(19,:) \cdot V(:,20); \quad Y_{22} = X(13,:) \cdot V(:,19)$$

$X_R =$

$$Y_{11} = X(:,1) \cdot V(:,20)$$

$$Y_{12} = X(:,1) \cdot V(:,19)$$

$$X_{1R} = Y_{11} V(:,20) + Y_{12} V(:,19) + \text{mean}$$

③ faces.bmp → data → cada imagem 60x50 pixels → vetor de dimensão 3000

3.1 directions

3000  
2999  
2998  
⋮  
8  
7  
6  
5  
4  
3  
2  
1

eigenvectors  
-1,5089x10<sup>-9</sup>  
-9,5263x10<sup>-10</sup>  
-6,1747x10<sup>-10</sup>  
-8,5152x10<sup>-10</sup>  
-4,7816x10<sup>-10</sup>

7 change

→ 8,0461x10<sup>5</sup>  
→ 1,0545x10<sup>6</sup>  
→ 1,1319x10<sup>6</sup>  
→ 1,2258x10<sup>6</sup>  
→ 3,6722x10<sup>6</sup>

6 número de componentes necessárias para reconstruir corretamente as imagens deverá ser 23

3.2

• Ao dar o comando showing (redes (:, 2555 : 3600)) (média ?)  
as imagens que surgem são bastante desfocadas, sendo imperceptíveis as expressões de cada pessoa.

?

3.3

Última mudança significativa  $\rightarrow$  20 f/21 componentes

$\rightarrow$  18 para reconhecer bem a pessoa

$\rightarrow$  20 f/ reconhecer expressões faciais

$\rightarrow$  Nessa fase inicial, as imagens são praticamente irreconhecíveis tal como em 3.2  
 $\rightarrow$  A partir de certo número de principal components, já é possível reconhecer a pessoa, sendo possível verificar as expressões faciais  
 $\rightarrow$  Posteriormente, as imagens quase não se alteram

3.4

$\rightarrow$  6 critério é extremamente a redução dos componentes que contribuem de forma mais significativa para a variância

$\rightarrow$  Para tal, fez-se o gráfico de  $\lambda_i^2 = \sum_{i=1}^{3000} \lambda_i$  e procura-se um "knee" no gráfico resultante

$\rightarrow$  Para a utilização de <sup>um número</sup> componentes superiores a 23 (onde se encontra o "knee", a contribuição de cada componente adicional para a redução do erro da variância praticamente não é notória

$\rightarrow$  Esta procura do knee corresponde aproximadamente a retirar apenas a informação correspondente à data inicial e a fazer ignorar os componentes que correspondem a ruído, realizando desta forma "denoising"